Excelente pregunta, Renzo. 🔥
Y sí: en la práctica real, entre **60% y 80% del tiempo** de un analista se va en limpieza y preparación de datos.

Si quieres hacerlo **10/10 nivel profesional**, necesitas un **prototipo mental + técnico reutilizable**, no solo "quitar nulos".

Aquí tienes un framework universal que puedes aplicar a **cualquier proyecto**, sea ventas, finanzas, marketing, logística o RRHH.

🧠 FRAMEWORK PROFESIONAL DE LIMPIEZA DE DATOS (DATA CLEANING 10/10)

Piensa en esto como una metodología en 7 fases:

```
1. Entender el negocio
2. Auditoría inicial del dataset
3. Estandarización estructural
4. Limpieza de calidad de datos
5. Tratamiento avanzado (outliers, inconsistencias)
6. Validación contra reglas de negocio
7. Documentación y versionado
```

🔎 FASE 1: ENTENDER EL CONTEXTO (ANTES DE TOCAR LOS DATOS)

! Esto es lo que separa a un analista promedio de uno profesional.

Preguntas obligatorias:

- ¿Qué problema de negocio estamos resolviendo?
- ¿Qué métrica importa realmente? (ventas, churn, conversión, margen)
- ¿Qué representa cada variable?
- ¿Cómo se recolectaron los datos?
- ¿Hay múltiples fuentes?

¿Por qué es crítico?

Porque **no puedes limpiar bien algo que no entiendes**.

Ejemplo:
Si una columna tiene valores negativos, ¿es error o son devoluciones?

📊 FASE 2: AUDITORÍA INICIAL (DATA PROFILING)

Aquí haces una radiografía completa del dataset.

2.1 Ver estructura general

- Número de filas
- Número de columnas
- Tipos de datos
- Primeras filas
- Últimas filas

En Python normalmente usarías:

- `.shape`
- `.info()`
- `.describe()`
- `.head()`

Pero lo importante no es el código, sino lo que analizas:

✓ ¿Hay columnas que deberían ser numéricas pero están como texto?
✓ ¿Hay fechas mal formateadas?
✓ ¿Hay columnas completamente vacías?

2.2 Revisión de valores nulos

Analiza:

- % de nulos por columna
- Patrón de nulos (¿aleatorios o sistemáticos?)

💡 Regla profesional:

% de nulos	Acción recomendada
< 5%	Imputar
5–30%	Analizar impacto
> 40%	Evaluar eliminar columna

Pero esto depende del contexto.

2.3 Revisión de duplicados

- Filas completamente duplicadas
- Duplicados por ID
- Duplicados parciales

Preguntas clave:

- ¿Es error?
- ¿Es una venta repetida?
- ¿Es actualización histórica?

Nunca elimines duplicados sin entender el modelo de negocio.

🏗️ FASE 3: ESTANDARIZACIÓN ESTRUCTURAL

Aquí haces que el dataset sea coherente.

3.1 Estandarizar nombres de columnas

Convierte todo a:

```
snake_case
sin espacios
sin caracteres especiales
```

Ejemplo:
`Fecha Venta` → `fecha_venta`

Esto facilita análisis y evita errores.

3.2 Corregir tipos de datos

- Fechas → datetime
- IDs → string
- Montos → float
- Categorías → category

Un error clásico:
ID numérico tratado como número (y luego pierde ceros a la izquierda).

🧹 FASE 4: LIMPIEZA DE CALIDAD DE DATOS

Aquí empieza la limpieza real.

4.1 Tratamiento de valores nulos

Opciones:

- Eliminar filas
- Imputar con media
- Imputar con mediana
- Imputar con moda
- Imputación por grupo
- Crear categoría "Desconocido"

💡 Nivel 10/10:
Nunca imputes sin justificarlo en documentación.

4.2 Corrección de inconsistencias categóricas

Ejemplo:

```
Lima
lima
LIMA
Líma
```

Se unifica todo.

También:

```
M
Masculino
Male
```

Se estandariza a un solo valor.

4.3 Limpieza de texto

- Eliminar espacios
- Quitar caracteres especiales
- Pasar a minúsculas
- Normalizar acentos

Esto evita que “Lima ” sea distinto a “Lima”.

FASE 5: OUTLIERS (VALORES ATÍPICOS)

Aquí muchos fallan.

No todo outlier es error.

Ejemplo:
Una venta de 1 millón puede ser:

- Error de digitación
- Cliente corporativo grande

Métodos para detectar:

- IQR
- Z-score
- Percentiles

Regla profesional:
Nunca elimines outliers sin consultar contexto.

Opciones:

- Eliminarlos
- Winsorizarlos
- Transformarlos
- Dejarlos si son reales

📐 FASE 6: VALIDACIÓN CON REGLAS DE NEGOCIO

Esta es la parte más profesional.

Creas reglas como:

- La edad no puede ser negativa
- La fecha de entrega ≥ fecha de compra
- El precio no puede ser menor a 0
- El descuento no puede ser mayor al 100%

Aquí detectas errores que ningún método estadístico detecta.

📄 FASE 7: DOCUMENTACIÓN (LO QUE TE HACE SENIOR)

Aquí está el nivel experto.

Debes documentar:

- Qué columnas eliminaste
- Qué valores imputaste
- Qué reglas aplicaste
- Qué outliers trataste

- Por qué tomaste cada decisión

Esto es clave si trabajas con:

- Microsoft
- Amazon
- Google

En empresas grandes, todo debe ser reproducible.

🏆 CHECKLIST PROFESIONAL (GUÁRDALO)

Antes de pasar a análisis o modelado, verifica:

✓ No hay tipos incorrectos
✓ No hay duplicados injustificados
✓ No hay columnas basura
✓ Los valores categóricos están estandarizados
✓ Las fechas tienen coherencia
✓ Los outliers están evaluados
✓ Las reglas de negocio se cumplen
✓ Todo está documentado

🧠 MENTALIDAD 10/10

Un analista junior limpia así:

“Quité nulos y ya.”

Un analista senior limpia así:

“Apliqué una estrategia estructurada basada en reglas de negocio, validación estadística y documentación reproducible.”

⚡ BONUS: Flujo Universal en Python (conceptual)

Siempre estructura tu notebook así:

```
1. Importación de librerías
2. Carga de datos
3. Data profiling
4. Limpieza estructural
5. Limpieza de calidad
6. Tratamiento de outliers
7. Validación final
8. Exportación dataset limpio
```

Nunca mezcles análisis con limpieza.

🎯 LO MÁS IMPORTANTE

La limpieza no es técnica.
Es estratégica.

El objetivo no es “datos bonitos”.
Es:

👉 Datos confiables para tomar decisiones.

Si quieres, puedo ahora:

- 🔷 Hacer un prototipo detallado con código profesional reutilizable
- 🔷 Crear un PDF de estudio avanzado
- 🔷 Simular un caso real (ventas retail o empresa peruana)
- 🔷 Enseñarte cómo defender esta limpieza en una entrevista

Tú decides el siguiente nivel, Renzo. 🚀

FIN

Perfecto, Renzo. 🔥

Vamos a hacer una **simulación realista nivel empresa peruana**, como si fueras analista en una cadena retail en Trujillo.

🏢 CASO REAL SIMULADO

Empresa: “Comercial Andina” (Retail Multisucursal)

La empresa tiene tiendas en:

* Trujillo
* Lima
* Chiclayo

Vende:

* Electrodomésticos
* Tecnología
* Hogar

🎯 PROBLEMA DE NEGOCIO

La gerencia detecta que:

* Las ventas han crecido 8%

* Pero la utilidad solo 2%

* Hay quejas por precios inconsistentes

* Hay diferencias entre ventas del sistema y ventas reportadas

Tu misión como analista:

- Limpiar el dataset de ventas para generar un reporte confiable de rentabilidad por ciudad y categoría.

📦 DATASET SIMULADO (ventas_2025.csv)

Columnas:

Columna	Descripción
id_venta	ID transacción
fecha	Fecha venta
ciudad	Ciudad
producto	Nombre producto
categoria	Categoría
precio_unitario	Precio venta
costo_unitario	Costo
cantidad	Unidades
descuento	% descuento
cliente_id	ID cliente

Total: 25,000 filas

🚨 PROBLEMAS DETECTADOS (COMO EN VIDA REAL)

Después del profiling inicial encuentras:

1. 3% de valores nulos en `costo_unitario`
2. 12% de valores nulos en `descuento`
3. Ciudades mal escritas:
   * trujillo
   * Trujilo
   * TRUJILLO
4. Categorías inconsistentes:
   * Tecno
   * Tecnología
   * tecnologia
5. 150 registros duplicados
6. 20 ventas con precio negativo
7. 8 ventas con descuento mayor a 100%
8. 50 registros con fecha futura (2027)
9. Outliers en precio (ej: S/ 99,999 por un mouse)
10. Cliente_id numérico con pérdida de ceros iniciales

Esto es completamente realista.

🔎 PASO A PASO: LIMPIEZA PROFESIONAL

🧠 PASO 1: VALIDACIÓN ESTRUCTURAL

✓ Convertir fecha a datetime

Porque puede venir como texto.

✓ cliente_id → string

Porque es identificador, no número matemático.

🧹 PASO 2: LIMPIEZA DE TEXTO

Estandarizar ciudad

Todo:

* Minúsculas

* Sin espacios

* Corrección ortográfica

Resultado final permitido:

* trujillo

* lima

* chiclayo

Estandarizar categoría

Mapa profesional:

```text
“tecno”, “tecnologia” → “tecnología”

“hogar “, “Hogar” → “hogar”
```

Nunca dejes categorías duplicadas por error humano.

🗑️ PASO 3: DUPLICADOS

Primero analizar:

¿Duplicado exacto?

¿Mismo id_venta repetido?

Si es duplicado completo → eliminar.

Si mismo id pero distinto detalle → investigar (puede ser error de sistema).

📉 PASO 4: VALORES IMPOSIBLES

Precio negativo

Regla negocio:

- Ninguna venta puede tener precio < 0.

Acción:

* Revisar si es devolución.

* Si no hay columna que indique devolución → eliminar o corregir.

Descuento > 100%

Error lógico.

Se elimina o corrige si es digitación (ej: 150% → 15%).

Fecha futura

No se pueden tener ventas del 2027 si estamos en 2025.

Eliminar o verificar carga incorrecta.

🧮 PASO 5: TRATAMIENTO DE NULOS

costo_unitario (3%)

Opciones:

* Imputar con mediana por categoría
* O usar promedio por producto

Nivel profesional:

Imputar por grupo (categoria).

---

descuento (12%)

Si negocio permite ventas sin descuento:

Imputar con 0.

Pero documentar:

- Se asumió que descuento nulo implica 0%.

📊 PASO 6: OUTLIERS

Detectas:

Mouse a S/ 99,999

Aplicar IQR.

Confirmar con negocio:

¿Es venta corporativa?

¿Error digitación?

Si error → corregir o eliminar.

📐 PASO 7: CREAR MÉTRICAS CLAVE

Ahora sí puedes crear:

* ingreso = precio_unitario * cantidad

* costo_total = costo_unitario * cantidad

* utilidad = ingreso – costo_total

* margen = utilidad / ingreso

Antes NO.

📋 PASO 8: VALIDACIÓN FINAL

Checklist:

✓ No hay valores negativos

✓ No hay descuento >100

✓ No hay fechas futuras

✓ Ciudades estandarizadas

✓ Categorías coherentes

✓ No hay duplicados

✓ No hay nulos críticos

📈 RESULTADO FINAL

Ahora puedes responder:

* Rentabilidad por ciudad

* Rentabilidad por categoría

* Productos con margen negativo

* Impacto de descuentos en utilidad

Y ahora sí el gerente puede confiar en el reporte.

🎯 LO QUE ACABAS DE HACER

Esto es lo que hace un analista en empresas reales.

Esto mismo ocurre en empresas como:

* Falabella

* Ripley

* Intercorp

🚀 NIVEL SIGUIENTE

Si quieres ahora puedo:

1. Simular el código completo en Python profesional

2. Simular cómo presentarías esto en comité gerencial

3. Crear dataset falso y limpiarlo paso a paso

4. Hacer versión entrevista laboral (cómo explicarlo)

Tú decides el siguiente nivel, Renzo.

FIN

Excelente pregunta, Renzo. 🔥

Ahora vamos a analizarlo como analista senior.

La respuesta corta es:

👉 **Sí, las aplicamos todas.**

Pero ahora te voy a demostrar exactamente **dónde y cómo**, para que lo veas con claridad metodológica.

✅ VERIFICACIÓN FASE POR FASE

1️⃣ ENTENDER EL NEGOCIO

¿Lo hicimos? ✓ Sí.

Al inicio definimos:

* Problema: ventas crecen 8% pero utilidad solo 2%.

* Sospecha: errores en precios, descuentos o costos.

* Objetivo: rentabilidad por ciudad y categoría.

Eso es entender el negocio antes de tocar datos.

Además contextualizamos con ciudades como Trujillo, Lima y Chiclayo.

Eso evita limpiar “a ciegas”.

2️⃣ AUDITORÍA INICIAL DEL DATASET (DATA PROFILING)

¿Lo hicimos? ✓ Sí.

Identificamos:

* % de nulos (3% costo, 12% descuento)
* Duplicados (150)
* Fechas futuras
* Valores negativos
* Descuentos > 100%
* Outliers extremos

Eso es profiling.

No limpiamos primero.

Primero diagnosticamos.

Eso es profesional.

3️⃣ ESTANDARIZACIÓN ESTRUCTURAL

¿Lo hicimos? ✓ Sí.

Acciones aplicadas:

* Convertir fecha a datetime

* cliente_id → string

* Estandarizar nombres de ciudades

* Estandarizar categorías

* Normalizar texto

Eso es estructura y formato.

4️⃣ LIMPIEZA DE CALIDAD DE DATOS

¿Lo hicimos? ✓ Sí.

Trabajamos:

* Nulos (imputación estratégica)

* Corrección de inconsistencias categóricas

* Eliminación de duplicados

* Corrección de texto

Aquí empieza la limpieza “real”.

5️⃣ TRATAMIENTO AVANZADO

¿Lo hicimos? ✓ Sí.

Incluimos:

* Outliers con IQR
* Validación de precios extremos
* Análisis contextual (¿error o venta corporativa?)
* Reglas de coherencia matemática

Eso ya es nivel intermedio/avanzado.

6️⃣ VALIDACIÓN CONTRA REGLAS DE NEGOCIO

¿Lo hicimos? ✓ Sí.

Aplicamos reglas como:

* Precio ≥ 0
* Descuento ≤ 100%
* Fecha ≤ fecha actual
* No margen negativo ilógico

Esto es lo que separa a un analista técnico de uno estratégico.

7️⃣ DOCUMENTACIÓN Y VERSIONADO

Aquí viene lo interesante.

⚠️ En la simulación lo mencioné, pero no lo desarrollamos formalmente.

En un entorno real harías:

* Archivo `data_cleaning_log.md`
* Versionado con Git
* Dataset original intacto
* Dataset limpio exportado como:

  * ventas_raw.csv
  * ventas_clean_v1.csv
  * ventas_clean_v2.csv

Empresas como Microsoft o Amazon no aceptan limpieza sin trazabilidad.

Ahí es donde muchos analistas se quedan en nivel 6/10.

📊 CONCLUSIÓN HONESTA

Sí aplicamos las 7 fases.

Pero:

Fase	Nivel aplicado
1	✓ Completo
2	✓ Completo
3	✓ Completo
4	✓ Completo
5	✓ Completo
6	✓ Completo
7	⚠️ Conceptual, no implementado

Si implementáramos documentación formal y versionado reproducible → sería 10/10 real corporativo.

🧠 LO MÁS IMPORTANTE QUE ACABAS DE HACER

Lo que preguntaste es pensamiento senior.

Un junior pregunta:

- ¿Cómo limpio esto?

Un analista sólido pregunta:

- ¿Estoy siguiendo una metodología estructurada?

Eso es mentalidad profesional.

Si quieres, ahora podemos:

* 🔎 Simular la fase 7 completa con documentación real
* 🧪 Hacer el mismo caso pero con datos financieros
* 💻 Implementarlo con código estructurado profesional
* 🎯 Convertir esto en discurso para entrevista

Tú eliges el siguiente nivel, Renzo.